

ACCOM - Revisão de Atividades

Explorando o software R, com interesse em economia e finanças

11 de julho de 2019

Resumo

Esse relatório integra todas as atividades desenvolvidas desde o início do projeto relacionado a exploração do software R, dessa forma, será explicitado todas as simulações de preços utilizando os modelos ARIMA e o ARFIMA, como também toda a análise para cada objeto de estudo.

1 Objetivo

Devido ao aumento de criptomoedas no mercado financeiro, foi estudado a série de preços de várias criptomoedas, utilizando os modelos de análise de preços de ordem não fracionária (ARIMA), e o modelo de ordem não fracionária (ARFIMA), para obter as previsões futuras da dinâmica de preços, que são voláteis devido a diversos fatores, sendo esses a política empregada no País,

2 Rascunho

2.0.1 Introdução Modelo ARIMA

As séries temporais são considerados processos estocásticos, isso devido as variáveis serem probabilísticos;

Uma série temporal é composta por três elementos: tendências, ciclos e a sazonalidade

- Tendência: é o comportamento a longo prazo de uma série, demonstrando sua volatilidade, ou seja, o quanto sobe e desce os seus dados perante determinado tempo, como também, diz qual é a velocidade que ocorre essas mudanças, as tendências mais comuns são as CONSTANTES, LINEAR E QUADRÁTICAS.
- Sazonalidade: A repetição de um padrão dentro de um período de tempo é o que caracteriza em uma série temporal.
- Ciclos: São repetições de um padrão em um período superior a um ano, por exemplo ciclos relacionados com a atividade economica.

- Ruído aleatório ou erro: Compreende a variabilidade dos dados, e não é possível ser modelado.

Uma série temporal a princípio possuem suposições que são estacionárias, devido elas se desenvolverem no tempo aleatoriamente ao redor de uma média constante, obtendo um equilíbrio mais estável. Porém, as séries econômicas possuem em geral tendências, ou seja, com inclinações positivas ou negativas (tendência linear)

Pode existir a não-estacionariedade explosiva

Quando uma série temporal possui média e variância, ambas dependem do tempo. deve-se ao fato de não ser estacionária, essa não-estacionariedade pode implicar que exista uma inclinação nos dados de modo que eles não permanecem ao redor de uma linha horizontal. Vale ressaltar ainda que a estacionariedade tem papel importante na absorção de choques que podem estar, eventualmente, presentes na série.

2.0.2 Simulações ARIMA

Foi estudado primeiramente a simulação do Lucas Trevisan, para a série de preços de milho no período correspondente a 01/01/2009 a 10/02/2015. Assim, inicialmente para obter o modelo ARIMA (p,d,q), é necessário testar a estacionariedade da série, pelo teste Dick-Fuller (ADF), isso mostra se a série possui flutuações, ou seja, se ela possuir alguma tendência, significa que a mesma apresenta média e variância dependentes do tempo, esse comportamento indica que a série é não estacionária. Caso a série possua uma oscilação entre uma média constante, caracteriza que ela seja estacionária. Por tal motivo, o teste ADF é capaz de reponder o comportamento da série, através de uma análise estatística, na qual é avaliado o teste de hipótese nula de que a série é não estacionária, o que indicaria que a existência de raiz unitária. Porém, a estacionariedade é importante para mostrar a absorção de choques presentes na série.

A distribuição do teste ADF é representado por τ , apresentando a seguinte regra de decisão:

H_0 : Não-estacionariedade;

H_1 : Estacionariedade;

Se t valor $< \tau$ representa estacionariedade, assim, a hipótese nula H_0 é rejeitada, e a série estudada é estacionária. A série apresentará a raiz unitária se a hipótese nula não for rejeitada, ou seja, é necessário fazer a diferenciação e submetida a um novo teste até obter t valor $> \tau$.

Dessa forma, utilizou-se os seguintes códigos, presentes na apostila de *Claudio Inácio*, para o teste ADF:

```
I { summary(ur.df(dados,type="trend",lags=12,selectlags="BIC"))
    summary(ur.df(dados,type="drift",lags=12,selectlags="BIC"))
    summary(ur.df(dados,type="none",lags=12,selectlags="BIC")) }
```

- Premissa:

A interpretação pode ser feita da seguinte maneira:

- $t \text{ valor} = z.lag.1$
- $\tau = tau5pct$

Assim sendo, para a função ser considerada estacionária, é necessário $z.lag.1 < \tau = tau5pct$.

A seguir as figuras relacionadas ao primeiro teste ADF:

Figura 1: 1º Teste ADF para estacionariedade em tendência na série da soja.
`> summary(ur.df(w,type="trend",lags=12,selectlags="BIC"))`

```

              Estimate Std. Error t value Pr(>|t|)
(Intercept)  6.453e-02  4.453e-02   1.449 0.147517
z.lag.1      -1.789e-03  1.677e-03  -1.067 0.286295
tt          -2.031e-05  1.767e-05  -1.150 0.250516
z.diff.lag1  7.007e-02  2.501e-02   2.802 0.005147 **
z.diff.lag2  6.486e-02  2.505e-02   2.590 0.009691 **
z.diff.lag3 -4.203e-02  2.502e-02  -1.680 0.093176 .
z.diff.lag4  9.239e-02  2.499e-02   3.697 0.000226 ***
---

Critical values for test statistics:
      lpct  5pct 10pct
tau3 -3.96 -3.41 -3.12

```

Figura 2: 1º Teste ADF para estacionariedade em torno de uma constante na série da soja.)

`> summary(ur.df(w,type="drift",lags=12,selectlags="BIC"))`

```

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)  0.063043   0.044517   1.416 0.156921
z.lag.1      -0.002337   0.001608  -1.453 0.146349
z.diff.lag1  0.071537   0.024979   2.864 0.004240 **
z.diff.lag2  0.066244   0.025019   2.648 0.008182 **
z.diff.lag3 -0.040573   0.024992  -1.623 0.104694
z.diff.lag4  0.094004   0.024953   3.767 0.000171 ***

Critical values for test statistics:
      lpct  5pct 10pct
tau2 -3.43 -2.86 -2.57
phil  6.43  4.59  3.78

```

Figura 3: 1º Teste ADF para estacionariedade em tendência não padrão para a série da soja.

```
> summary(ur.df(w,type="none",lags=12,selectlags="BIC"))
Coefficients:
      Estimate Std. Error t value Pr(>|t|)
z.lag.1      -9.451e-05  2.804e-04  -0.337 0.736147
z.diff.lag1   7.040e-02  2.497e-02   2.819 0.004881 **
z.diff.lag2   6.508e-02  2.501e-02   2.602 0.009360 **
z.diff.lag3  -4.183e-02  2.498e-02  -1.674 0.094272 .
z.diff.lag4   9.265e-02  2.494e-02   3.714 0.000211 ***
---
Critical values for test statistics:
      1pct  5pct 10pct
taul -2.58 -1.95 -1.62
```

As informações da série, como demonstrado nas figuras [1], [2], [3], foram resumidas na Tabela [1]:

Tabela 1: Resumo do comportamento da série temporal da soja.

Comportamento	t valor	τ_{5pct}	Ocorrência	Situação
Tendência	-1.067	-3.41	$t > \tau_{5pct}$	Não estacionário
Constante	-1.453	-2.86	$t > \tau_{5pct}$	Não estacionário
Não Padrão	-0.337	-1.95	$t > \tau_{5pct}$	Não estacionário

Visto que a série não é estacionária, temos que H_0 não foi rejeitada, dessa forma, é necessário fazer a diferenciação da série através da função *diferenca_dados* < *-diff(dados)*, a n quantidades de vezes diferenciadas, representa a variável (d) dos modelos ARIMA (p, d, q) e ARFIMA (p, d, q), ou seja, a tomada de decisão para diferenciar a série é estabelecida até tornar a série estacionária, após a diferença realiza novamente os testes ADF.

Observação: Caso o valor do parâmetro $d = 0$, ou seja, a série fosse estacionária, sem necessitar a realização da diferença, o modelo será estimado como um ARMA (p, q).

Assim, é utilizado as mesmas funções de (I), porém foi alterado para a variável *diferenca_dados* e não foi utilizado a variável *dados* como no primeiro teste.

Figura 4: 2º Teste ADF para estacionariedade em tendência na série da soja.

```
> summary(ur.df(diferenca_w,type="trend",lags=12,selectlags="BIC"))
```

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	1.979e-02	1.575e-02	1.256	0.20924
z.lag.1	-8.200e-01	4.625e-02	-17.730	< 2e-16 ***
tt	-2.540e-05	1.696e-05	-1.498	0.13434
z.diff.lag1	-1.109e-01	4.045e-02	-2.741	0.00619 **
z.diff.lag2	-4.736e-02	3.417e-02	-1.386	0.16592
z.diff.lag3	-9.116e-02	2.497e-02	-3.651	0.00027 ***

Critical values for test statistics:

	1pct	5pct	10pct
tau3	-3.96	-3.41	-3.12
phi2	6.09	4.68	4.03

Figura 5: 2º Teste ADF para estacionariedade em constante na série da soja.

```
> summary(ur.df(diferenca_w,type="drift",lags=12,selectlags="BIC"))
```

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	-0.0007433	0.0077680	-0.096	0.923778
z.lag.1	-0.8140602	0.0460971	-17.660	< 2e-16 ***
z.diff.lag1	-0.1152289	0.0403618	-2.855	0.004361 **
z.diff.lag2	-0.0503520	0.0341209	-1.476	0.140225
z.diff.lag3	-0.0927909	0.0249539	-3.718	0.000207 ***

Critical values for test statistics:

	1pct	5pct	10pct
tau2	-3.43	-2.86	-2.57
phi1	6.43	4.59	3.78

Figura 6: 2º Teste ADF para estacionariedade em tendência não padrão na série da soja.

```
> summary(ur.df(diferenca_w,type="none",lags=12,selectlags="BIC"))

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
z.lag.1      -0.81404    0.04608 -17.665 < 2e-16 ***
z.diff.lag1  -0.11524    0.04035  -2.856 0.004343 **
z.diff.lag2  -0.05036    0.03411  -1.476 0.140030
z.diff.lag3  -0.09279    0.02495  -3.720 0.000206 ***
---
Critical values for test statistics:
          1pct  5pct 10pct
taul -2.58 -1.95 -1.62
```

As informações da série, como demonstrado nas figuras [4], [5], [6], foram resumidas na Tabela [2].

Tabela 2: Resumo do comportamento da série temporal da soja, após a 1ª diferenciação.

Comportamento	t valor	τ_{5pct}	Ocorrência	Situação
Tendência	-17.730	-3.41	$t < \tau_{5pct}$	Estacionário
Constante	-17.660	-2.86	$t < \tau_{5pct}$	Estacionário
Não Padrão	-17.665	-1.95	$t < \tau_{5pct}$	Estacionário

Depois da diferenciação, pode-se concluir que a hipótese nula foi rejeitada, assim sendo, temos uma série estacionária. A partir disso, é realizado as análises FACP e FAC através das funções de autocorrelações, essas são necessárias para estimar o modelo ARIMA (p, d, q) , quando plotadas em gráfico, apresentam limites superiores e inferiores, delimitando a região dos valores não significativos do modelo, ou seja, os “lags” que ultrapassam esses limites são valores estatisticamente significativos, caso não, têm-se valores que são considerados não significativos.

Sabendo que as funções FAC e FACP determinam os parâmetros do modelo, geralmente, a ordem do modelo AR(p) é definida quando FAC é declinante e FACP é truncada em um valor. Já em um modelo MA(q) é identificado quando as funções possuem um comportamento no qual FAC é truncado em um valor e FACP é declinante. (TREVISAN, Lucas, 2015)

Em síntese, o primeiro valor que ultrapassar o limiar de confiança, é esse que representa a ordem procurada, entretanto, pode-se existir mais de uma ordem do modelo para a determinada série, dessa forma, realiza-se o BIC e o menor

valor registrado representa o melhor modelo. O lag “0” não se considera na análise.

Na série estudada, foi utilizado para o FAC, e o FACP, as funções $fac < -acf(diferenca_dados, lag.max = 12)$, $fap < -pacf(diferenca_dados, lag.max = 12)$, respectivamente, e plotados os gráficos como estão representados nas Figuras [7],[8]:

Figura 7: Análise FAC na série da soja.





Figura 8: Análise FACP na série da soja.



Como indicado nos gráficos com a seta vermelha, é visível que os limites que ultrapassaram primeiro o limite de confiança, é no lag 1 tanto para análise FAC, quanto para o FACP, dessa forma, o modelo adequado para essa análise é o ARMA (1,1). Consequente, precisa partir para a análise do critério de informação (BIC ou AIC), o qual indica se o modelo a ser aplicado é o melhor, por tal motivo, a checagem dos parâmetros.

O melhor modelo ARIMA é aquele em que os valores dos resíduos se encontram dentro dos limites de confiança, assim sendo, menor for o BIC.

Lembrando que a série foi diferenciada $d = 1$, o modelo utilizado é o ARIMA(1, 1, 1), fazendo o BIC para constatar o modelo, foi realizado através das análises FAC e FACP dos resíduos do modelo, estão representadas nas Figuras [9][10].

Figura 9: Análise do BIC do FAC na série da soja.

```
> fac<-acf(w.fit$residuals)
```





Figura 10: Análise do BIC do FACP na série da soja.


```
fapc<-pacf(w.fit$residuals)
```



Nas duas figuras supracitadas, possuem valores dos resíduos que influenciam significativamente, pois existem lags que ultrapassam o limite de confiança, porém não descarta a possibilidade de adotar o modelo ARIMA(1, 1, 1), à vista disso, a fim de checar a melhor ordem, e consequentemente encontrar a melhor previsão, optou nessa análise utilizar a função Forecast, no qual possui a ferramenta Auto arima(), esse código é o mais utilizado nas previsões, pela sua automação nos resultados e validação dos critérios de informação pelo “BIC”, “AIC” e “AICc”, dessa forma, possui uma conclusão mais assertiva.

Após aplicado a ferramenta, obteve-se outra ordem para o modelo, sendo o ARIMA(5, 1, 2), conforme a figura [11].

Figura 11: Previsão a partir do modelo ARIMA(5, 1, 2) para a série da soja.



Nessa previsão foi estimado os melhores parâmetros, avaliando os critérios de informação, esses dizem qual é o melhor modelo a ser adotado para a série. Os valores dos parâmetros, os coeficientes e os critérios do modelo ARIMA(5, 1, 2) foram resumidos na tabela [3]. Os coeficientes AR(p) estão representados por *ar1* e *ar2* e os coeficientes MA(q) estão representados por *ma1* e *ma2*, com essas informações, possibilita a comparação da ordem desse modelo em relação ao adotado por TREVISAN, aferindo qual obteve o melhor desempenho.

Tabela 3: Coeficientes e critério do modelo ARIMA(5, 1, 2) encontrados no R.

Coeficientes	Valor	Critério	Valor
<i>ar1</i>	0.4076	<i>BIC</i>	866.6
<i>ar2</i>	0.3859	<i>AICc</i>	823.64
<i>ma1</i>	-0.3464	<i>AIC</i>	823.55
<i>ma2</i>	-0.3583		

Segundo TREVISAN, a ordem do seu modelo é ARIMA(2, 1, 2), a sua previsão e os coeficiente estão representados na Figura [12], e na Tabela [4], respectivamente.

Figura 12: Previsão a partir do modelo ARIMA(2, 1, 2) para a série da soja.




Tabela 4: Coeficientes e critério do modelo ARIMA(2, 1, 2) encontrados no R.

Coeficientes	Valor	Critério	Valor
<i>ar1</i>	-0.7952	<i>BIC</i>	860.63
<i>ar2</i>	-0.1396	<i>AICc</i>	833.76
<i>ma1</i>	0.8654	<i>AIC</i>	833.72
<i>ma2</i>	0.2507		

2.0.3 Discussão

Tendo em vista os valores mencionados, na previsão realizada por TREVISAN em 2015, em primeira análise o critério BIC adotado pelo modelo ARIMA(2, 1, 2) possui o valor de 860,63, de fato esse BIC é o menor em relação a previsão do ARIMA(5, 1, 2) que é 866,6, isso pressupõe que o modelo adotado por ele é

o melhor, entretanto a sua análise só leva em consideração um único critério de informação, devido as limitações da ferramenta Forecast utilizado naquele cenário, atualmente há conhecimento do código Forecast mais efetivo, na qual *Claudio Inácio* apresenta em seu material, as atualizações leva em consideração o Drift da série, além de comparar os critérios de informação BIC, AIC e AICc, assim, encontrando a ordem de melhor ajuste a série. Como pode ser observado na Tabela [3], os critérios AIC e AICc são menores que do modelo adotado por TREVISAN, vide Tabela [4].

2.1 Modelo ARFIMA

O modelo ARFIMA, foi modelado a partir da função `Arfima()`, ferramenta pertencente ao pacote `FORECAST{}`, como já mencionado, essa função está desenvolvida em relação com aquela utilizada por TREVISAN em 2015, dessa forma, possui diferenças com a previsão feita por ele, vale a ressalva que a utilização dessa ferramenta, é usualmente utilizado diretamente para a previsão devido a complexidade em avaliar as funções FAC e FACP, como também a estacionariedade, uma vez que a essa acaba sendo inviável analisar pois a diferenciação a partir desse modelo assume valores no intervalo de 0 a 0.9 diferentemente do ARIMA que são números inteiros, como esse trabalho é somente um parâmetro de comparação e aprendizagem, foi simulado seguindo os mesmos passos de TREVISAN, analisando a previsão de 365 dias após os dados coletados.

A seguir na Figura [13], apresenta o gráfico do comportamento da série na previsão dos preços, na qual os preços previstos estão destacados em azul. Na Tabela [5] e [6], fornece os coeficientes da série e os valores nos próximos 20 dias de previsão, respectivamente, a fim de demonstrar os dados da intrínsecos do modelagem na qual o programa R fornece.

Figura 13: Previsão a partir do modelo ARFIMA(0,0.499,5) para a série da soja.




Tabela 5: Coeficientes do modelo ARFIMA(0,0.499,5) encontrados no R.

Coeficientes	Valor
D	0,499
$ma1$	-0.635
$ma2$	-0.552
$ma3$	-0.427
$ma4$	-0.367
$ma5$	-0.204

Tabela 6: Valores das previsões com máximos e mínimos a partir do modelo ARFIMA.

Dia	Data	Observação	Preço Previsão	Preço Mínimo 80%	Preço Máximo 80%	Preço Mínimo 95%	Preço Máximo 95%
1	11/06/2015	5,5886	20,3254	19,8473	20,8036	19,5942	21,0567
2	12/06/2015	5,5914	20,5519	19,8286	21,2751	19,4458	21,6580
3	13/06/2015	5,5943	20,9223	19,9859	21,8587	19,4902	22,3544
4	14/06/2015	5,5971	21,4004	20,2887	22,5120	19,7002	23,1005
5	15/06/2015	5,6000	21,5732	20,3093	22,8371	19,6402	23,5061
6	16/06/2015	5,6029	22,0435	20,6674	23,4196	19,9390	24,1480
7	17/06/2015	5,6057	22,3902	20,9479	23,8326	20,1843	24,5961
8	18/06/2015	5,6086	22,5537	21,0621	24,0452	20,2725	24,8348
9	19/06/2015	5,6114	22,7125	21,1816	24,2435	20,3711	25,0539
10	20/06/2015	5,6143	22,4069	20,8432	23,9707	20,0153	24,7985
11	21/06/2015	5,6171	22,4458	20,8539	24,0377	20,0112	24,8804
12	22/06/2015	5,6200	22,6207	21,0042	24,2372	20,1484	25,0930
13	23/06/2015	5,6229	22,5033	20,8649	24,1416	19,9976	25,0090
14	24/06/2015	5,6257	22,5096	20,8516	24,1676	19,9739	25,0453
15	25/06/2015	5,6286	22,5303	20,8545	24,2062	19,9674	25,0933
16	26/06/2015	5,6314	22,6410	20,9489	24,3332	20,0531	25,2289
17	27/06/2015	5,6343	22,9827	21,2755	24,6898	20,3718	25,5936
18	28/06/2015	5,6371	23,0458	21,3247	24,7668	20,4136	25,6779
19	29/06/2015	5,6400	23,2702	21,5362	25,0042	20,6182	25,9221
20	30/06/2015	5,6429	23,1828	21,4367	24,9290	20,5124	25,8533